

厦门大学林子雨编著

《Python 程序设计基础教程（微课版）》

教材习题 答案

第 14 章 网络爬虫

（版本号：2022 年 1 月版本）



主讲教师：林子雨
厦门大学数据库实验室
二零二二年一月

一、简答题

1.请阐述什么是网络爬虫。

【参考答案】

网络爬虫是一个自动提取网页的程序，它为搜索引擎从万维网上下载网页，是搜索引擎的重要组成部分。如图 14-1 所示，爬虫从一个或若干个初始网页的 URL 开始，获得初始网页上的 URL，在抓取网页的过程中，不断从当前页面上抽取新的 URL 放入队列，直到满足系统的一定停止条件。

2.请阐述网络爬虫有哪些类型。

【参考答案】

网络爬虫的类型可以分为通用网络爬虫、聚焦网络爬虫、增量式网络爬虫、深层网络爬虫。

3.请阐述什么是反爬机制。

【参考答案】

为什么会有反爬机制？原因主要有两点：第一，在大数据时代，数据是十分宝贵的财富，很多企业不愿意让自己的数据被别人免费获取，因此，很多企业都为自己的网站运用了反爬机制，防止网页上的数据被爬走；第二，简单低级的网络爬虫，数据采集速度快，伪装度低，如果没有反爬机制，它们可以很快地抓取大量数据，甚至因为请求过多，造成网站服务器不能正常工作，影响了企业的业务开展。

4.请阐述用 Python 实现 HTTP 请求的常见的 3 种方式。

【参考答案】

Python 实现 HTTP 请求的常见的 3 种方式：urllib、urllib3 和 requests。

5.请阐述如何定制 requests。

【参考答案】

定制 requests 的方式包括传递 URL 参数、定制请求头、发送 POST 请求和设置超时等。

6.请阐述使用 BeautifulSoup 解析 HTML 可以使用哪些解析器？各有什么优缺点？

【参考答案】

解析器	用法	优点	缺点
Python 标准库	BeautifulSoup(markup,"html.parser")	Python 标准库 执行速度适中	文档容错能力差
lxml 的 HTML 解析器	BeautifulSoup(markup,"lxml")	速度快 文档容错能力强	需要安装 C 语言库
lxml 的 XML 解析器	BeautifulSoup(markup,"lxml-xml") BeautifulSoup(markup,"xml")	速度快 唯一支持 XML 的解析器	需要安装 C 语言库
html5lib	BeautifulSoup(markup,"html5lib")	兼容性好 以浏览器的方式解析文档 生成 HTML5 格式的文档	速度慢，不依赖外部扩展

二、编程题

1、访问豆瓣电影 Top250 (<https://movie.douban.com/top250?start=0>)，获取每部电影的中文片名、排名、评分及其对应的链接，按照“排名-中文片名-评分-链接”的格式显示在屏幕上。

【参考答案】

```
import requests
from bs4 import BeautifulSoup
import time

# 请求网页
def page_request(url, ua):
    response = requests.get(url=url, headers=ua)
    html = response.content.decode('utf-8')
    return html

# 解析网页
def page_parse(html):
    soup = BeautifulSoup(html, 'lxml')
    # 获取每部电影的排名
    position = soup.select('#content > div > div.article > ol > li > div > div.pic > em')
    # 获取豆瓣电影名称
    name = soup.select('#content > div > div.article > ol > li > div > div.info > div.hd > a > span:nth-child(1)')
    # 获取电影评分
    rating = soup.select('#content > div > div.article > ol > li > div > div.info > div.bd > div > span.rating_num')
    # 获取电影链接
    href = soup.select('#content > div > div.article > ol > li > div > div.info > div.hd > a')
    for i in range(len(name)):
        print(position[i].get_text()+"\t"+name[i].get_text()+"\t" + rating[i].get_text() + "\t" + href[i].get('href'))

if __name__ == "__main__":
    print('*****开始爬取豆瓣电影*****')
    ua = {'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; WOW64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/90.0.4421.5 Safari/537.36'}
    # 豆瓣电影 Top250 每页有 25 部电影，start 就是每页电影的开头
    for startNum in range(0, 251, 25):
        url = "https://movie.douban.com/top250?start=%d" % startNum
        html = page_request(url=url, ua=ua)
        page_parse(html=html)
    print('*****爬取完成*****')
```

2、访问豆瓣电影 Top250 (<https://movie.douban.com/top250?start=0>)，在问题 1 的基础上，获取每部电影的导演、编剧、主演、类型、上映时间、片长、评分人数以及剧情简介等信息，并将获取到的信息保存至本地文件中。

【参考答案】

```
import requests
from bs4 import BeautifulSoup
import re
import docx
from docx.oxml.ns import qn

# 请求网页
def page_request(url, ua):
    response = requests.get(url=url, headers=ua)
    html = response.content.decode('utf-8')
    return html

# 解析网页
def page_parse(html, ua):
    soup = BeautifulSoup(html, 'lxml')
    for tag in soup.find_all(attrs={'class': 'item'}):
        data = []
        # 序号
        num = tag.find('em').get_text()
        data.append(num)
        # 电影名称
        name = tag.find_all(attrs={'class': 'title'})[0].get_text()
        data.append(name)
        # 豆瓣链接
        href = tag.find(attrs={'class': 'hd'}).a
        url = href.attrs['href']
        data.append('豆瓣链接:' + url)
        # 评分与评论数
        info = tag.find(attrs={'class': 'star'}).get_text()
        info = info.replace("\n", "").lstrip()
        # 使用正则表达式获取数字
        mode = re.compile(r'd+\.\d+')
        i = 0
        for n in mode.findall(info):
            if i == 0:
                # 评分
                data.append('豆瓣评分:' + n)
            elif i == 1:
                # 评分人数
                data.append('评分人数:' + n)
            i = i + 1
        # 进入子网页，获取每部电影的具体信息
        sub_page_requests(url, ua, data)
```

```
print('第%s 部电影信息爬取完成' % num)

# 子网页处理函数：进入并解析子网页/请求子网页
# 获取影片详细信息
def sub_page_requests(url, ua, data):
    html = page_request(url=url, ua=ua)
    soup = BeautifulSoup(html, 'lxml')
    # 影片信息
    info = soup.find(attrs={'id': 'info'}).get_text()
    data.append(info)
    # 影片简介
    summary = soup.find(attrs={'property': 'v:summary'}).get_text()
    summary = summary.replace('\n', "").replace(' ', "").lstrip()
    data.append(data[1] + '影片简介:\n' + summary)
    # 保存影片信息
    save(data)

def save(data):
    file = docx.Document()
    # 设置字体格式
    file.styles['Normal'].font.name = u'Times New Roman'
    file.styles['Normal'].element.rPr.rFonts.set(qn('w: eastAsia'), u'Times New Roman')

    # 将爬取到的数据写入 word 中
    for element in data:
        file.add_paragraph(element)
    file.save('result/' + data[0] + '、' + data[1] + '.docx')

if __name__ == "__main__":
    print('*****开始爬取豆瓣电影*****')
    ua = {'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; WOW64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/90.0.4421.5 Safari/537.36'}
    # 豆瓣电影 Top250 每页有 25 部电影，start 就是每页电影的开头
    data_List = []
    for startNum in range(0, 251, 25):
        url = "https://movie.douban.com/top250?start=%d" % startNum
        html = page_request(url=url, ua=ua)
        # 获取每部影片的信息
        page_parse(html=html, ua=ua)
    print('*****爬取完成*****')
```

3、访问微博热搜榜（<https://s.weibo.com/top/summary>），获取微博热搜榜前 50 条热搜名称、链接及其实时热度，并将获取到的数据通过邮件的形式，每 20 秒发送一次到个人邮箱中。

【参考答案】

```
# 爬虫相关模块
import requests
from bs4 import BeautifulSoup
# 发送邮箱相关模块
import smtplib
from email.mime.text import MIMEText
from email.header import Header
# 定时模块
import schedule
import time

# 请求网页
def page_request(url, ua):
    response = requests.get(url=url, headers=ua)
    html = response.content.decode('utf-8')
    return html

# 解析网页
def page_parse(html):
    soup = BeautifulSoup(html, 'lxml')
    news = []
    # 处理热搜前 50
    urls_title = soup.select('#pl_top_realtimehot > table > tbody > tr > td.td-02 > a')
    hotness = soup.select('#pl_top_realtimehot > table > tbody > tr > td.td-02 > span')
    for i in range(len(urls_title)):
        new = {}
        title = urls_title[i].get_text()
        url = urls_title[i].get('href')
        # 个别链接会出现异常
        if url == 'javascript:void(0);':
            url = urls_title[i].get('href_to')
        # 热搜 top 没有显示热度
        if i == 0:
            hot = 'top'
        else:
            hot = hotness[i - 1].get_text()

        new['title'] = title
        new['url'] = "https://s.weibo.com" + url
        new['hot'] = hot
        news.append(new)
    for element in news:
        print(element['title'] + '\t' + element['hot'] + '\t' + element['url'])
# 发送邮件
```

```
sendMail(news)

# 将获取到的热搜信息发送到邮箱
def sendMail(news):
    # 发送邮箱
    from_addr = '发送邮箱'
    # 发送邮箱授权码，不是邮箱密码，而是 smtp 授权码
    password = '发送邮箱授权码'
    # 接收邮箱
    to_addr = '接收邮箱'
    # qq 邮箱的 smtp 地址
    maihost = 'smtp.qq.com'
    # 建立 SMTP 对象
    qqmail = smtplib.SMTP()
    # 25 为 SMTP 常用端口
    qqmail.connect(maihost, 25)
    # 登录邮箱
    qqmail.login(from_addr, password)
    # 设置发送邮件的内容
    content = ""
    for i in range(len(news)):
        content += str(i) + '、\t' + news[i]['title'] + '\t' + '热度:' + news[i]['hot'] + '\t' + '链接:' +
news[i][
        'url'] + '\n'

    get_time = time.strftime('%Y-%m-%d %X', time.localtime(time.time())) + '\n'
    content += '获取事件时间为' + get_time

    # 设置邮件的格式以及发送主题
    msg = MIMEText(content, 'plain', 'utf-8')
    msg['subject'] = Header('微博热搜', 'utf-8')

    try:
        qqmail.sendmail(from_addr, to_addr, msg.as_string())
        print('succeed sending')
    except:
        print('fail sending')
    qqmail.quit()

def job():
    print('*****开始爬取微博热搜*****')
    ua = {
        'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; WOW64) AppleWebKit/537.36
(KHTML, like Gecko) Chrome/90.0.4421.5 Safari/537.36'}
```

```
url = 'https://s.weibo.com/top/summary'
html = page_request(url=url, ua=ua)
page_parse(html)

if __name__ == "__main__":
    # 定时爬取，每隔 20s 爬取一次微博热搜榜并将爬取结果发送至个人邮箱
    schedule.every(20).seconds.do(job)
    while True:
        schedule.run_pending()
```

附录 1:任课教师介绍




林子雨，男，博士（毕业于北京大学），厦门大学计算机科学系副教授，厦门大学信息学院实验教学中心主任。2013 年度、2017 年度和 2020 年度厦门大学教学类奖教金获得者。中国计算机学会数据库专业委员会委员，中国计算机学会信息系统专业委员会委员，厦门大学数据库实验室负责人，数据中国“百校工程”教育部专家组成员。负责的“大数据技术原理与应用”课程获评“2018 年国家精品在线开放课程”和“2020 年国家级线上一流本科课程”。负责的“Spark 编程基础”课程获评“2020 年福建省线上一流本科课程”。国内高校首个“数字教师”的提出者和建设者，编著出版了国内高校第一本系统介绍大数据知识的专业教材《大数据技术原理与应用》，成为国内众多高校开课教材，同时建设了国内高校首个大数据课程公共服务平台，为教师教学和学生学习大数据课程免费提供全方位、一站式服务，平台累计访问量超过 1000 万次，成为国内高校大数据教学知名品牌，并获得“2018 年福建省教学成果二等奖”和“2018 年厦门大学教学成果特等奖”。

E-mail: ziyulin@xmu.edu.cn

个人主页: <http://dblab.xmu.edu.cn/linziyu>

数据库实验室网站: <http://dblab.xmu.edu.cn>

附录 2：课程教材介绍



出版社：人民邮电出版社

ISBN: 978-7-115-57519-7 定价：59.8 元

出版时间：2021 年 1 月第 1 版

本书详细介绍了获得 Python 基础编程能力所需要掌握的各方面技术。全书共 15 章，内容包括 Python 语言概述、基础语法知识、程序控制结构、序列、字符串、函数、面向对象程序设计、模块、异常处理、基于文件的持久化、基于数据库的持久化、图形用户界面编程、正则表达式、网络爬虫、常用的标准库和第三方库等。本书每个章节都安排了入门级的编程实践操作，以便读者更好地学习和掌握 Python 编程方法。本书官网免费提供了全套的在线教学资源，包括讲义 PPT、习题、源代码、软件、数据集、上机实验指南等。



扫一扫访问教材官网